

LLM金融ABMにおける内部表現介入の伝播分解 — 研究設計 v0.3

一行サマリー「LLM内部表現が市場を作った」ではなく、{内部表現 / 条件付き注文フロー / 市場フィードバック} のどこに説明力があるかを分解する。これがこの研究の核心。

0. ステータス

- バージョン: v0.3 (v0.2 に対する設計レビューを反映)
 - 段階: 設計確定前。実装(pilot)に入る直前。
 - 次の作業: 下流(7条件×2モード)の拡張ではなく、**Stage 2 同定 + micro gate + pilot** を固めること。
-

1. 研究の核心

自然なLLMトレーダーの内部には、ATHや購入価格などの参照点に反応して売買判断を変える内部表現があると仮説する。その表現に因果介入(抑制・再注入・増幅)し、効果が

1. 個体の売買非対称性(ミクロ)
2. 市場レベルのATHアノマリー(マクロ)

へどう伝播するかを測る。

ただし主張は素朴な「内部表現が市場アノマリーを生成した」ではない。因果鎖のどの区間に説明力があるかを分解することがこの研究の固有性。

2. 位置取り(なぜ空白か)

「金融ABMのmech-interp」という語には三つの別物が同居している。混同すると新規性が崩れる。

バ ケ ツ	内容	前例	本研究との関係
1	ABM 出力 の解釈可能性(透 明なルールエージェントで sim を可読化、OT分解 等)	多数(Neri L-FABS 等、Izumi研の Interpretable Market Sim via OT)	別物("interpretable" の別義)
2	金融タスクでのLLMの mech-interp(単一モデル・隔 離)	少数・増加中(Barclays "Beyond the Black Box" 2505.24650、 Golgoon et al. 2407.11215)	隣接。市場結合なし
3	LLMエージェントを金融 ABM に入れ、内部介入が市場統 計へ伝播するのを測る	ほぼゼロ	本研究

当事者の自己申告でも空白が裏付けられる:FCLAgent論文は「LLMの金融ABM統合は未開拓」、Barclays論文は mech-interp は「まだ広く採用されていない」。

最近接の先行研究(差別化必須):

- **Yee & Sharma (2026), arXiv:2602.01022** — LLMを行動パラメータの測定器として校正し、calibrated parameter を資産価格ABMに埋め込む。ただし外部応答からの校正であって内部介入ではない。重要な含意: ベースラインLLMは損失回避が減衰・disposition ほぼゼロ(→ 後述の attenuated baseline 問題)。
- **A Financial Brain Scan of the LLM, arXiv:2508.21285** — SAEで金融的特徴をクラスタ化、リスク回避をsteer。ただし隔離。市場結合なし。
- **Steering Risk Preferences in LLMs, arXiv:2505.11615** — 行動表現と神経表現を整合させてsteering vectorを作る。やはり隔離。
- **FCLAgent (Hashimoto et al. 2510.12189)** — 本研究の市場基盤。LLMが売買方向、価格/数量はルール。ただし内部介入はしていない。

差別化一行: 既存は (a) 外部校正 + ABM埋め込み、または (b) 隔離での内部steering。本研究は内部因果介入を多エージェント市場に閉ループで戻し、内部表現/条件付き注文フロー/市場フィードバックを分解する。

3. 主張の二段分割

段	主張	強度	担う実験
A. エージェント機構	参照点依存の売買傾向を内部表現への介入で因果的に操作できる(マイクロ因果)	強く言える	KO / Rescue / Amp
B. 市場機構	その内部表現が市場レベルのATHアノマリーを生成している	そのままでは弱い	要 ZI control

Bを守る条件: 同じ条件付き売買傾向を持つが内部表現を持たない**統計ゾンビ(ZI)**では再現できないことを示す。示せないなら、正直に:

マクロ効果は注文フロー統計に還元可能であり、LLM内部表現の貢献は「なぜその注文フロー傾向が生じるか」というマイクロ機構にある。

これは敗北ではなく、Farmer的に通りやすい誠実な定式化。

4. 因果分解の骨格(逐次媒介)

研究全体を逐次媒介 / 分散分解として書く。場合分けの羅列ではなく、これを背骨にする。

internal representation

→ conditional policy

→ order flow

→ market feedback

→ price-path statistics

実験	見る因果区間
KO / Rescue micro	internal representation → conditional policy
Replay	conditional policy → order flow
ZI replay	LLM方策が統計的方策に圧縮できるか
Closed-loop	order flow → market feedback → price statistics
Shadow replay	feedbackなしの価格応答
Closed vs shadow	feedback amplification

マクロ総効果を三つに分割する:

1. **ZI-2** で吸収される分(条件付き方策を経由する効果)
2. **ZI-2** を超える**LLM**残差(手書き特徴より高次・履歴依存の条件づけ)
3. **closed – replay flow residual**
または
closed – shadow-price residual

「どこまでが認知の話で、どこからが市場構造の話か」を分解できる点が固有の面白さ。

5. 用語定義(保存用)

WT / KO / Rescue / Amp

遺伝学の knockout screen からの借用。市場ではなくエージェントの内部状態のラベル。市場基盤は同一で、LLMエージェントの内部表現 **S_ATH** をどういじったかを指す。介入は重みを変えず推論時の活性に対して行う。

- **WT (wild-type)**: 介入なしの自然なLLMエージェント。
- **KO (knockout)**: **S_ATH** 方向を活性から除去。単位方向 $\hat{s}$ に対し $h' = h - (h \cdot \hat{s})\hat{s}$ (射影除去)、またはSAE特徴を0クランプ。
- **Rescue**: KO状態に再注入 $h' = h_{KO} + \alpha \cdot \hat{s}$ 。off-target否定の決定打(遺伝学のゴールドスタンダード)。
- **Amp**: $\hat{s}$ 方向に $\alpha > 0$ でsteer。baselineより強く押す(用量依存)。

KO(必要性) + Rescue(off-target否定) + Amp(用量依存) が揃うと因果主張がほぼ反論不能。

βh

標準的な金融用語ではない。FCLAgent論文 式(8) のローカル記法。ある回帰の傾き:

$$p_{\{t+T\}} / p_t = \text{const} + \beta^h \cdot (p_t / p^h_{\{1:t\}})$$

- $p^h_{\{1:t\}}$ = 時刻tまでの全期間最高値(running all-time high)
- $p_t / p^h_{\{1:t\}}$ = **ATH**近接度(1.0なら今がピーク、<1なら下落中)= 説明変数
- $p_{\{t+T\}} / p_t$ = horizon T 先の将来リターン比 = 被説明変数
- β^h = OLS傾き。上付き h は high。

意味: ATHに近いほど将来リターンが低いという実証アノマリー(Li & Yu 2012)の定量化。実データで $\beta^h < 0$ 。「KOで β^h が負からゼロへ動く」=「ATH参照表現を消すと市場のATHアノマリーが消える」。ノイズが巨大(**SD > mean**)なので **primary endpoint** にしすぎない。

開ループ / 閉ループ

着目するのは エージェント↔市場のフィードバックループ(市場の開場/閉場とは無関係)。

- 閉ループ (**closed-loop**): エージェント決定が価格を更新 → 新状態 → 次の決定…。内生・動的・創発あり。だが条件ごとに軌道が分岐し高ノイズ。
- 開ループ (**replay**): WTを一度走らせ状態系列を録画 → 同一の固定系列を各条件のエージェントに読ませ、注文だけ見る(価格に戻さない)。フィードバック切断。決定関数の変化を低ノイズで純粹分離。創発は失う。

ZI zombie (統計ゾンビ)

内部表現も推論も持たないが、WT LLMの条件付き売買傾向 $\pi_{WT}(a|x)$ だけを再現する統計機械 (lookup / logistic / GAM / random forest)。ABMでは $a \sim \pi_{WT}(a|x)$ で注文。

- **ZI-0**: 平均 buy/sell 比だけ一致 (trivial control)
- **ZI-1**: ATH近接度 + 含み益/損 で条件付き一致 (**Farmer control** の本丸)
- **ZI-2**: full policy (ATH, 購入価格, 損益, OFI, ファンダ乖離, 直近リターン, cash/position) で一致 (mechanism-matched control)

6. モード別 observables (v0.3 最重要修正)

replay と **closed-loop** は、**flow**観測量と **price-path**観測量で妥当性が非対称。ここを混線させない。

Replay で読めるもの (flow専用)

価格パスが凍結＝全条件で同一なので、価格パス統計は **degenerate**。読めるのは意思決定・注文フロー系のみ。

- 読む: $P(\text{sell} \mid \text{ATH condition})$ 、PGR/PLR、ATH近傍sell probability、order-direction divergence、sell imbalance、WT vs KO 方向差分、WT vs ZI 方策一致度
- 読まない: β_h 、drawdown、crash frequency、return skewness、downside return、volatility (全部 price-path 統計)

Closed-loop で読めるもの (price-path)

価格が分岐するので、ここで初めて価格パス統計を見る。

- 読む: β_h 、drawdown、downside volatility、return skewness、crash frequency、volume、price impact
- caveat: 軌道分岐 → ZI比較に covariate shift が入る (§7)

Shadow-price replay (価格系の open-loop baseline が欲しい場合)

各時点でKOの注文を凍結された板に一回だけ当て、反実価格変化を計算するが次時点に戻さない（非複利）。これで「feedbackなしの価格応答」が定義できる。

feedback amplification は2種類に分ける

旧 $A_{\beta h} = \Delta\beta h_{\text{closed}} / \Delta\beta h_{\text{replay}}$ は壊れていた(replayで βh は全条件恒等 $\rightarrow$ 分母0 $\rightarrow$ 未定義)。修正:

- **Flow amplification** (通常replayで定義可) $A_{\text{flow}} = \Delta\text{sell_imbalance_closed} / \Delta\text{sell_imbalance_replay}$
- **Price amplification** (shadow-price replay を作った場合のみ) $A_{\text{price}} = \Delta\beta h_{\text{closed}} / \Delta\beta h_{\text{shadow}}$

通常replayを価格系の分母にしてはいけない。

解釈:

結果

解釈

$A \approx 0$ ミクロ効果が市場で吸収された

$A \approx 1$ closed-loopはreplayの延長。創発弱い

$A > 1$ **feedback amplification** あり(狙い目)

$A < 0$ 市場フィードバックが効果を反転

7. ZI zombie の使い方

Clean ZI comparison: replay (covariate shift なし)

同一の凍結状態列 x_t に対し $LLM_{WT} / LLM_{KO} / ZI_{WT_policy} / ZI_{KO_policy}$ を比較。状態分布が同じなので shift がない。見るのは方策一致度、 $P(\text{sell} | ATH)$ 、sell imbalance、order-direction divergence。

ここでZIがWTの注文フローを十分模倣できるなら:「WTのミクロ方策は、少なくとも観測特徴上の条件付き注文ルールに圧縮できる」。

Noisy ZI comparison: closed-loop (必ず caveat 付き)

ZIは自分の誘導分布で別軌道を生み、 π_{WT} の訓練分布外を訪れる (behavioral cloning の covariate shift)。やるなら:

- overlap診断 (ZIが訪れた状態がWT訓練分布内か)
- importance weight / density ratio
- DAgger式の再学習 (ZI自身の誘導分布上でLLM方策を再問い合わせ更新)
- 外挿領域を別表示 (OOD割合を必ず報告)

これをしないと $WT > ZI$ を「LLM固有の認知」とは読めない。

「LLM固有」は言いすぎ。正しくは「ZI-2 で指定した特徴集合では、WT LLMの実効方策を十分に閉ループ模倣できなかった」=「ZI-2 を超える高次・履歴依存的な条件づけ」まで。原理的には ZI-3 (全履歴・ニュース本文) で吸収しうる。これは model-organism 枠 (LLMは高次・経路依存の条件づけを手で書かずに得る手段) と同じ地点に着く。

8. Stage 2 同定 (最大の gate — ここが転けたら全部無意味)

「参照点関連内部表現」という便利語を、実装可能な同定手順に落とす。

2.1 paired prompt

同じ市場状態で参照点だけ変える。購入価格効果とATH効果は混ぜず別々に同定 (S_{ATH} と $S_{purchase}$)。

A: current price 95, purchase price 80, ATH 100

B: current price 95, purchase price 80, ATH 95

2.2 行動差が出るペアだけ使う

教師信号は「reference condition そのもの」ではなく「reference condition によって売買判断が変わったか」。そうしないと「ATHという文字を読んでる特徴」を拾うだけになる。

2.3 activation差分

MVPでは SAE にこだわらず **residual stream** の差分方向から:

$v_{ATH} = \text{mean}(h_{\text{clean}} - h_{\text{control}})$ (層ごと)

どの層の v_{ATH} を steer / project out すると $P(\text{sell} | \text{ATH})$ が動くかを見る。SAEは第2段階。

2.4 control方向の直交化(必須)

以下を別途作り、 v_ATH から control subspace を射影除去: general risk aversion / cash preference・inactivity / pessimism / fundamental valuation / numerical sensitivity / generic sell bias。

1. control directionを別データセットで作る
2. v_ATH とのcosine similarityを報告
3. 直交化前後でmicro phenotype effectを比較
4. held-out promptでspecificityを検証

これをしないと「KOで売りが減った」が「単に慎重さを壊しただけでは？」に潰される。

2.5 micro gate(下流に行く前の合格条件)

- **Gate 1 (KO):** $KO(v_ATH)$ が ATH条件付き売り非対称を減らす
- **Gate 2 (Specificity):** ファンダ感応を壊さない／単に hold・cash を増やすだけでない／全条件の売りを一様に減らさない
- **Gate 3 (Rescue):** KO + 再注入で ATH条件付き売り非対称が戻る

この3つを満たして初めて Stage 4 以降へ。

9. Pilot(伽藍の前に)

pilot	測るもの	失敗時
A: baseline phenotype	中立プロンプトで PGR>PLR / ATH sell asymmetry が出るか	モデルかpromptを変える
B: micro intervention	KOでどれだけ減るか / Rescueでどれだけ戻るか (効果量)	Stage 2 へ戻る
C: paired Δ分散	closed-loop 少数seedで $\Delta\beta h_seed = \beta h_KO - \beta h_WT$ の分散	seed数を見積もる

必要seed数:

$$n \approx ((1.96 + 0.84) \cdot s_{\Delta} / \delta)^2$$

s_{Δ} = ペア内差分の標準偏差
 δ = 検出したい平均効果

このpilotなしで 7条件×2モード には行かない。matched-seed の paired design が βh の SD>mean問題の救いだが、ペア内 Δ 分散は「はず」でなく実測する。

10. 結果パターンと解釈(どの結果でも論文になる)

結果	条件	主張
A: LLM だけ強い	WT > ZI, closed > replay	内部表現が条件付き注文フロー以上の文脈依存性を持ち、閉ループで増幅。最高
B: ZI で再現	WT $\approx$ ZI, closed > replay	マクロは注文フロー統計に還元可能。内部表現はそのマイクロ機構を与える
C: 増幅なし	closed $\approx$ replay	参照点バイアスは線形伝播。非線形創発増幅は見られず
D: micro 効くが βh 動かず	KO/Rescue効く, βh 不動	内部表現は個体判断に因果的。マクロは市場ノイズ・流動性に吸収 → ミクロ機構論文

ただし注意: この頑健性はマクロの尻尾の話。真の break-or-make は上流 (Stage 1 baseline + Stage 2 同定 + Stage 3 clean micro KO)。結果A～Dの安心がここを覆い隠さないこと。

11. 実験設計 v0.3 (staged pipeline)

- Stage 1: Baseline phenotype
 - 中立プロンプトで PGR>PLR, ATH sell asymmetry を確認
- Stage 2: Identification
 - 行動差が出る paired prompt から v_{ATH} / v_{purchase} を同定、control直交化
- Stage 3: Micro KO/Rescue
 - WT / KO / Rescue / Amp。PGR/PLR, ATH sell asymmetry, specificity controls (Gate 1-3)
- Stage 4: Replay flow decomposition
 - 凍結状態列で WT/KO/Rescue/ZI を比較。flow metrics のみ
- Stage 5: Pilot closed-loop
 - 少数 matched seed で $\Delta\beta h$ とペア内分散 → power estimate

Stage 6: Full closed-loop

必要seed数で WT/KO/Rescue/Zombie。price-path metrics。ZIIには overlap診断 or DAgger

Optional Stage 7:

shadow-price replay で feedbackなし価格応答 → closed との差を amplification として

完全版は **7 conditions × 2 modes × matched seeds** (WT/KO/Rescue/Amp/ZI-0/ZI-1/ZI-2 × Replay/Closed-loop)。重いので Stage 5 のpower見積もり後に規模を決める。

12. 第一論文のスコープ境界

主役にしないもの:

対象	理由 / 扱い
Herding	Phase 2。社会信号リグ(複数LLM or OFI)が必要
Extrapolation	Phase 2。chartistルール層と競合(FCLAgentでchartistはLLM外)
Risk appetite	control(主仮説にしない)
Cash preference	negative control(売買抑制との混同を防ぐ)

まだ言わないこと:

- 人間の損失回避を発見した
- 市場の真の原因を特定した
- LLM内部特徴が人間認知と同じである
- herding/extrapolation/risk appetite をすべて分解した

用語規律:「損失回避特徴」と断定しない。**reference-point-related internal representation**(参照点関連の内部表現)= 基準点情報に反応しLLMの売買判断に影響する表現のまとめ、として扱う。

13. revised abstract

We investigate whether causal interventions on internal reference-point-related representations in LLM trading agents propagate to market-level anomalies. Using

matched-seed experiments, we first show that suppressing and rescuing these representations modulates individual-level disposition and all-time-high selling behavior. We compare LLM agents with zero-intelligence policy clones that approximate the observed conditional selling policy on matched replay states but contain no internal representations. Finally, we contrast replay and closed-loop simulations to test whether individual-level perturbations are amplified by market feedback. This design separates three mechanisms: internal representation, conditional order flow, and market microstructure feedback.

(和文)本研究は、LLMトレーダー内部の参照点関連表現への因果介入が市場レベルのアノマリーへ伝播するかを検証する。同一seedのペア実験により、まず内部表現の抑制・再注入が個体レベルの disposition および ATH近傍売りを変化させることを示す。次に、同じ条件付き売買方策を再現するが内部表現を持たない zero-intelligence エージェントと比較し、マクロ効果が認知表現に固有なのか注文フロー統計に還元可能なのかを判定する。最後に replay と closed-loop を比較し、個体レベルの摂動が市場フィードバックにより増幅されるかを検定する。本設計は内部表現・条件付き注文フロー・市場微細構造フィードバックの三機構を分離する。

14. 次の作業(伽藍拡張ではなく土台固め)

1. baseline prompt 設計(中立プロンプト=循環回避、ただし Yee-Sharma の attenuated baseline と衝突しうる)
2. paired prompt dataset 設計(行動差が出るペアのみ、S_ATH と S_purchase を分離)
3. v_{ATH} / $v_{purchase}$ 同定法の確定(residual-stream差分先行、SAEは第2段階)
4. micro KO/Rescue gate の実装(Gate 1-3)
5. pilot で paired Δ 分散の実測 + power estimate

未決の方法論選択:

- 最初のモデル: Llama-3.1-8B(FCLAgentとの連続性)か Gemma-2-9B(risk-pref steering の先例 2505.11615)
- 同定法: residual diff $\rightarrow$ SAE $\rightarrow$ behavioral-neural alignment、の順で硬くしていく
- baseline構築: 中立プロンプトで emergent に出すか、profile prompting で誘導するか(前者は循環回避だが弱信号リスク)

15. 主要参考文献

市場基盤・ABM

- Hashimoto, Takayanagi, Suzuki, Izumi (2025). Agent-Based Simulation of a Financial Market with Large Language Models. arXiv:2510.12189. (FCLAgent。本研究の基盤)

- Chiarella & Iori (2002). A simulation analysis of the microstructure of double auction markets. *Quantitative Finance* 2(5). (FCNAgent)
- Hirano, Takata, Izumi (2023). PAMS: Platform for Artificial Market Simulations. arXiv:2309.10729.
- Brock & Hommes (1998). Heterogeneous beliefs and routes to chaos in a simple asset pricing model. *JEDC* 22.
- Farmer & Foley (2009). The economy needs agent-based modelling. *Nature* 460.
- Axtell & Farmer (2025). Agent-Based Modeling in Economics and Finance: Past, Present, and Future. *JEL* 63(1):197–287.
- Farmer, Patelli & Zovko (2005). The predictive power of zero intelligence in financial markets. *PNAS*. (ZI traditionの本丸)

行動ファイナンス(参照点・disposition)

- Li & Yu (2012). Investor attention, psychological anchors, and stock return predictability. *JFE* 104(2). (ATHアノマリー βh の出典)
- Odean (1998). Are investors reluctant to realize their losses? *Journal of Finance* 53. (PGR/PLR)
- Kahneman & Tversky (1979); Tversky & Kahneman (1992). (プロスペクト理論)

LLMエージェント金融/経済シミュレーション

- Li, Gao, Li, Li, Liao (2024). EconAgent. *ACL 2024*.
- Yee & Sharma (2026). Calibrating Behavioral Parameters with Large Language Models. arXiv:2602.01022. (最近接の先行研究)
- A Financial Brain Scan of the LLM. arXiv:2508.21285.
- Steering Risk Preferences in LLMs by Aligning Behavioral and Neural Representations. arXiv:2505.11615.

mechanistic interpretability / steering

- Park et al. (2023). Generative Agents: Interactive Simulacra of Human Behavior. *UIST*. (memory stream の原型)
- Cunningham et al. (2023). Sparse Autoencoders Find Highly Interpretable Features in Language Models. arXiv:2309.08600.
- Turner et al. (2023). Steering Language Models With Activation Engineering. arXiv:2308.10248.
- Heimersheim & Nanda (2024). How to use and interpret activation patching. arXiv:2404.15255. (backup circuit の注意)
- Jain & Wallace (2019). Attention is not Explanation. *NAACL*. (attention を入口にしない根拠)
- Beyond the Black Box: Interpretability of LLMs in Finance. arXiv:2505.24650.
- Golgoon et al. (2024). Mechanistic interpretability of LLMs with applications to the financial services industry. arXiv:2407.11215.

この設計の急所は二つ。(1) *replay/closed-loop* の *observable* 非対称性 (*flow*専用 / *price*専用) を守ること。(2) 下流の伽藍より先に *Stage 2* 同定と *micro gate* を固めること。マクロ主張の弱点は、解釈可能性の方向 (*model-organism* 枠) と市場物理の方向 (*Farmer/ZI*) の両方から同じ場所——「内部表現か注文フロー統計か」——を指している。